

stat: my library of statistics

Nelson Luís Dias

May 26, 2024

1 reglina: a linear regression through the origin

Let

$$Y = ax + E \quad (1)$$

where Y is a random variable, E is a random variable independent of x , and x is not random.

Form the objective function

$$F_O(a) = \frac{1}{n} \sum_{i=1}^n (y_i - ax_i)^2 \quad (2)$$

Differentiating with respect to a gives the least-squares estimate of a :

$$\begin{aligned} \sum_{i=1}^n 2(y_i - ax_i)(-x_i) &= 0, \\ -\sum_{i=1}^n x_i y_i + a \sum_{i=1}^n x_i^2 &= 0, \\ a &= \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}. \end{aligned} \quad (3)$$

The “error” involved in estimating a can be found by re-interpreting a (and y_i) as random variables, and assuming that the Y_i ’s are independent:

$$\begin{aligned} A &= \frac{\sum_{i=1}^n x_i Y_i}{\sum_{i=1}^n x_i^2}, \\ \text{Var}[A] &= \frac{\sum_{i=1}^n x_i^2 \text{Var}[Y]}{[\sum_{i=1}^n x_i^2]^2}. \end{aligned} \quad (4)$$

Replacing the expectations with sample moments:

$$\begin{aligned} s_A^2 &= \frac{\sum_{i=1}^n x_i^2}{[\sum_{i=1}^n x_i^2]^2} s_Y^2, \\ s_A^2 &= \frac{s_Y^2}{\sum_{i=1}^n x_i^2}. \end{aligned} \quad (5)$$

The mean square error shouldn't be too difficult to find, now:

$$\begin{aligned}
s^2 &= \frac{1}{n} \sum_{i=1}^n [y_i - ax_i]^2 \\
&= \frac{1}{n} \sum_{i=1}^n [y_i^2 - 2ax_iy_i + a^2x_i^2] \\
&= \frac{1}{n} \left[\sum_{i=1}^n y_i^2 - 2a \sum_{i=1}^n x_iy_i + a^2 \sum_{i=1}^n x_i^2 \right].
\end{aligned} \tag{6}$$

2 stat_NO: um otimizador não-linear simples

Dado um conjunto de n pontos (x_i, y_i) , desejo ajustar uma função $f(x; \xi)$, onde $\xi = (\xi_1, \dots, \xi_m)$ é um vetor de m parâmetros. No caso mais geral (e talvez mais comum), f é não-linear em ξ .

O encaminhamento clássico da solução é procurar um ponto crítico de uma função objetivo. Defino

$$F(\xi) \equiv \sum_{i=1}^n [y_i - f(x_i; \xi)]^2 \tag{7}$$

Em um ponto crítico de F :

$$\frac{\partial F}{\partial \xi_i} \equiv 2G_i(\xi) = -2 \sum_{k=1}^n [y_k - f(x_k; \xi)] \frac{\partial f}{\partial \xi_i} = 0. \tag{8}$$

As equações (8), $i = 1, \dots, n$, podem ser resolvidas com um método de Newton-Raphson multi-dimensional, usando uma estimativa ξ_0 do ponto crítico e resolvendo

$$G_i(\xi_1) \approx G_i(\xi_0) + \sum_{j=1}^m \frac{\partial G_i(\xi_0)}{\partial \xi_j} (\xi_{1j} - \xi_{0j}) = 0 \tag{9}$$

para ξ_{1j} , $j = 1, \dots, m$. Calculo

$$\begin{aligned}
\frac{\partial G_i(\xi_0)}{\partial \xi_j} &= \sum_{k=1}^n \frac{\partial f(x_k; \xi_0)}{\partial \xi_j} \frac{\partial f(x_k; \xi_0)}{\partial \xi_i} - [y_k - f(x_k; \xi_0)] \frac{\partial^2 f}{\partial \xi_i \partial \xi_j} \\
&\approx \sum_{k=1}^n \frac{\partial f(x_k; \xi_0)}{\partial \xi_j} \frac{\partial f(x_k; \xi_0)}{\partial \xi_i}.
\end{aligned} \tag{10}$$

Em (10), estamos desprezando o termo envolvendo as derivadas segundas de f simplesmente porque temos a esperança de diminuir o nosso esforço analítico e computacional. Uma justificativa mais detalhada por ser encontrada em ?.

Seja J a matriz jacobiana cujos elementos são $\partial G_i / \partial \xi_j$; a solução de (9) em linguagem matricial é

$$\begin{aligned}
G + J \cdot [\xi_1 - \xi_0] &= 0 \\
J \cdot [\xi_1 - \xi_0] &= -G \\
[\xi_1 - \xi_0] &= J^{-1} \cdot [-G]
\end{aligned} \tag{11}$$

$$\xi_1 = \xi_0 + J^{-1} \cdot [-G] \tag{12}$$

com J e G avaliados em ξ_c .

Agora, as derivadas primeiras podem ser estimadas se eu tiver 2 pontos iniciais:

$$\xi_{1i} = \xi_{0i} + \Delta\xi_i; \quad (13)$$

$$\frac{\partial f(x_k; \xi_0)}{\partial \xi_i} \approx \frac{f(x_k; \xi_0 + \Delta\xi_i e_i) - f(x_k; \xi_0)}{\Delta\xi_i}. \quad (14)$$

Evidentemente, a derivada parcial na direção i envolve uma variação apenas na direção do vetor unitário e_i . Portanto, um algoritmo de cálculo pode ser iniciado a partir de um ponto ξ_0 no espaço de parâmetros, e um incremento “pequeno” $\Delta\xi$. Pode ser preciso especificar $\Delta\xi_i$ ’s diferentes para cada i .

O algoritmo em questão agora é:

- (a) Inicialize ξ_{0j} , $\Delta\xi_j$ e um critério de parada ϵ ;
- (b) calcule G_i com (8) para $\xi = \xi_0$, e $\partial f / \partial \xi_j$ com (14);
- (c) calcule $\partial G_i / \partial \xi_j$ com (10);
- (d) resolva o sistema de equações lineares (11) para $\Delta\xi = \xi_1 - \xi_0$;
- (e) Faça $\xi_0 = \xi_1$;
- (f) se $|\Delta\xi| < \epsilon$, páre; senão, volte para (b).